

# Lista de Exercícios 3

# Exercício 1

Você está interessado em desenvolver um modelo para estimar o tempo de execução de um algoritmo. Você tem razões para acreditar que dois parâmetros de configuração do algoritmo, A e B, sejam bons previsores para o tempo de execução do mesmo. Além disto, você acredita que cada um destes parâmetros impacte o tempo de execução de forma linear. Em outras palavras, você acredita que o tempo de execução do algoritmo possa ser previsto pela seguinte equação:

$$\text{Tempo} = b_0 + b_A x_A + b_B x_B$$

Utilizando os dados de **28** experimentos com seu algoritmo (cada um com valores diferentes de A e B), você realiza uma regressão linear múltipla e encontra os seguintes resultados:

$$b_0 = 13.5, \quad b_A = 0.47 \quad \text{e} \quad b_B = 1.72$$

$$sb_0 = 2.2, \quad sb_A = 0.018 \quad \text{e} \quad sb_B = 0.18$$

$$SST = 850.6 \quad \text{e} \quad SSR = 670.3$$

# Exercício 1

a) Qual porcentagem da variação dos dados é explicada pelos supostos previsores?

$$R^2 = \frac{SSR}{SST} = \frac{670.3}{850.6} = 78.80\%$$

# Exercício 1

b) Os previsores explicam uma fração significativa da variação? Justifique  
Isto equivale a perguntar se a regressão é significativa. Precisa fazer o teste-F.

$$SSR = 670.3$$

$$SSE = 850.6 - 670.3 = 180.3$$

$$MSR = SSR/k = 670.3/2 = 335.15$$

$$MSE = SSE/(n-k-1) = 180.3/(28 - 2 - 1) = 7.212$$

$$F\text{-calculado} = MSR/MSE = 46.47$$

$$F_{[90; 2,25]} = 2.53 \text{ (com 90\%)} \quad F_{[95; 2,25]} = 3.39 \text{ (com 95\%)}$$

Assim o teste F passa com 95% de confiança

# Exercício 1

c) Quais previsores são significativos? Justifique.

$$t_{0.975,25} = 2.06$$

IC de 95% de  $b_A$  :

$$b_A \pm t_{0.975,25} sb_A$$

$$0.47 \pm 2.06 * 0.018 : 0.47 \pm 0.037 \rightarrow \text{SIGNIFICATIVO}$$

IC de 95% de  $b_B = 1.72$

$$b_B \pm t_{0.975,25} sb_B$$

$$1.72 \pm 2.06 * 0.18 : 1.72 \pm 0.37 \rightarrow \text{SIGNIFICATIVO}$$

# Exercício 1


d) Há algum indício de multicolinearidade entre A e B? Por quê? Em caso afirmativo, descreva o que deverá ser feito para tratar este problema.

Não, não há já que todos os cálculos ( $R^2$ , teste-F e IC de preditores) são consistentes e apontam para um bom modelo.

## Exercício 2

Considere o exemplo da questão anterior. Suponha que você deseja verificar a relação custo-benefício de modelos alternativos. Em particular, você deseja verificar o benefício de um modelo baseado em um único previsor, o fator A. Porém, você perdeu os resultados referentes a grande parte dos experimentos realizados, restando apenas os dados abaixo. Supondo que a realização de novos experimentos seja inviável, você decide comparar o modelo anterior (analisado na questão anterior) com um modelo novo, derivado a partir dos dados abaixo. Qual a sua conclusão? Em outras palavras: o modelo com apenas um previsor (fator A) compensa?? Desenvolva a resposta.

A	8.5	8.9	10.6	11.6	13	13.2
Tempo de execução	30.9	32.7	36.7	46.3	46.2	47.8





# Exercício 2

$$\bar{x} = \frac{1}{n} \sum x_i = 10.9667$$

$$\sum xy = \sum x_i y_i = 2711.34$$

$$\bar{y} = \frac{1}{n} \sum y_i = 40.1$$

$$\sum x^2 = \sum x_i^2 = 741.62$$

$$b_1 = \frac{\sum xy - n \bar{x} \bar{y}}{\sum x^2 - n \bar{x}^2} = 72.76 / 20.01333 = 3.6356$$

$$b_0 = \bar{y} - b_1 \bar{x} = 0.2298$$

Tempo =  $b_0 + b_1 x_A$

A	8.5	8.9	10.6	11.6	13	13.2
Tempo de execução	30.9	32.7	36.7	46.3	46.2	47.8
Valor Predito	31.13	32.59	38.77	42.40	47.49	48.22
Erro	0.23	-0.11	2.07	-3.89	1.29	0.42

## Exercício 2

A	8.5	8.9	10.6	11.6	13	13.2
Tempo de execução	30.9	32.7	36.7	46.3	46.2	47.8

Valor Predito	31.13	32.59	38.77	42.40	47.49	48.22
Erro	0.23	-0.11	2.07	-3.89	1.29	0.42
Erro^2	0.054	0.013	4.27	15.19	1.67	0.18

$$SSE = 21.3755$$

$$SST = SSY - n\bar{y}^2 = 9933.96 - 6*(40.1)^2 = 285.9$$

$$R^2 = \frac{SST - SSE}{SST} = 92.52\% \rightarrow \text{SIM}$$

## Exercício 2

A	8.5	8.9	10.6	11.6	13	13.2
Tempo de execução	30.9	32.7	36.7	46.3	46.2	47.8

Valor Predito	31.13	32.59	38.77	42.40	47.49	48.22
Erro	0.23	-0.11	2.07	-3.89	1.29	0.42
Erro^2	0.054	0.013	4.27	15.19	1.67	0.18

$$SSE = 21.3755$$

$$SST = SSY - n\bar{y}^2 = 9933.96 - 6*(40.1)^2 = 285.9$$

$$R^2 = \frac{SST - SSE}{SST} = 92.52\% \rightarrow \text{SIM, o modelo com 1 previsor é melhor (R2 maior)}$$

# Exercício 3


Os tempos para criptografar registros de  $k$  bits em um computador A são mostrados na tabela abaixo. Responda:

k	Tempo (ms)
128	93
256	478
512	3408
1024	25410

# Exercício 3

Os tempos para criptografar registros de k bits em um computador A são mostrados na tabela abaixo. Responda:

k	Tempo (ms)
128	93
256	478
512	3408
1024	25410




Relação claramente não linear, deve tentar transformação

$$y = ae^{bx} \quad \rightarrow \quad y' = \ln(y) = b_0 + b_1x$$

# Exercício 3

Os tempos para criptografar registros de k bits em um computador A são mostrados na tabela abaixo. Responda:

k	Tempo (ms)	ln (tempo)
128	93	4.5326
256	478	6.1696
512	3408	8.1339
1024	25410	10.1429



Relação claramente não linear, deve tentar transformação

$$y = ae^{bx} \quad \rightarrow \quad y' = \ln(y) = b_0 + b_1x$$

# Exercício 3

a) Uma regressão linear pode ser aplicada diretamente aos dados? Justifique sua resposta. Em caso negativo, discuta o que você faria para obter uma relação entre tempo de criptografia e tamanho de registro. Apresente um modelo para esta relação.

Não, não pode pois a relação é claramente não linear. Deve-se fazer uma transformação. Optou-se por  $y' = \ln(y)$

$$y' = \ln(y) = b_0 + b_1x$$

# Exercício 3

b) Determine os valores dos parâmetros do seu modelo.

$$\bar{x} = \frac{1}{n} \sum x_i = 480$$

$$\sum xy = \sum x_i y_i = 16710.4677$$

$$\bar{y} = \frac{1}{n} \sum y_i = 7.2447$$

$$\sum x^2 = \sum x_i^2 = 1392640$$

$$b_1 = \frac{\sum xy - n\bar{x}\bar{y}}{\sum x^2 - n\bar{x}^2} = 0.005945$$

$$b_0 = \bar{y} - b_1 \bar{x} = 4.3909$$



# Exercício 3

c) Qual a porcentagem da variação é explicada pela regressão? Você está satisfeito com seu modelo? Se não, qual seria o seu próximo passo?

$$SSE = 1.0509$$

$$SST = SSY - SS0 = 227.6469 - 4 * 7.2447^2 = 17.7015$$

$$R^2 = \frac{SST - SSE}{SST} = 94.06\%$$

Modelo muito bom. Estou satisfeito. Poderia-se tentar outra transformação (e.g.,  $y = ax^b \rightarrow \ln(y) = \ln(a) + b\ln(x) \rightarrow \ln(y) = b_0 + b_1\ln(x)$ ) e verificar se ele é ainda melhor

# Exercício 3

d) Quais parâmetros são significativos, com uma confiança de 90%?

$$s_e = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{1.0509}{4-2}} = 0.7249$$

$$s_{b0} = se \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{\sum x^2 - n\bar{x}^2}} = 0.7249 * \sqrt{\frac{1}{4} + \frac{480^2}{1392640 - 4*480^2}} = 0.6232$$

$$s_{b1} = \frac{se}{\sqrt{\sum x^2 - n\bar{x}^2}} = \frac{0.7249}{\sqrt{1392640 - 4*480^2}} = 0.001056$$

$$t_{0.95,2} = 2.92$$

IC de 90% para      b0:  $4.3909 \pm 2.92 * 0.6232$  (SIGNIFICATIVO)

b1:  $0.005945 \pm 2.92 * 0.001056$  :     $0.005945 \pm 0.003084$   
(SIGNIFICATIVO)

# Exercício 3

e) Qual o tempo esperado para criptografar um registro de 384 bits? Quais limites você colocaria para esta estimativa se você aceita um erro máximo de 10% para uma única medida futura?

$$y' = \ln(y) = 4.3909 + 0.005945 * 384 = 6.6739 \rightarrow y = e^{6.6739} = 791.5416$$

IC de 90% na escala logaritma

$$s_y = s_e \sqrt{\frac{1}{m} + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum x^2 - n\bar{x}^2}} = 0.7249 \sqrt{1 + \frac{1}{4} + \frac{(384 - 480)^2}{1392640 - 4 * 480^2}} = 0.8168$$

$$t^* 0.8168 / 6.6739 \leq 0.1 \quad t_{(1-\alpha/2), 2} \leq 0.8171 \quad 1-\alpha/2 \leq 0.7$$

Confiança máxima (1-  $\alpha$ ) de 40%

# Exercício 4

O tempo de execução de um algoritmo foi medido em função de 2 parâmetros. Uma regressão linear múltipla, utilizando 7 observações, levou aos seguintes resultados:

j	0	1	2
$b_j$	-0.1614	0.1182	0.0165
$c_{jj}$	0.6297	0.0280	0.0012

Coeficiente de correlação múltipla: 0.99

$$s_e = 1.2$$

# Exercício 4

a) A regressão é significativa com 90% de confiança?

$$R = 0.99 \rightarrow R^2 = 98.01\%$$

$$s_e = \sqrt{\frac{SSE}{n-k-1}} = \sqrt{\frac{SSE}{7-2-1}} = 1.2 \rightarrow SSE = 1.2^2 * 4 = 5.76$$

$$\rightarrow MSE = s_e^2 = 1.2^2 = 1.44$$

$$R^2 = \frac{SSR}{SST} = \frac{SSR}{SSR+SSE} = \frac{SSR}{SSR+5.76} = 0.9801$$

$$SSR = 0.9801 * SSR + 5.6454 \rightarrow SSR = 283.6872$$

$$MSR = SSR/k = 283.6872/2 = 141.8436$$

$$F_{\text{comp}} = MSR/MSE = 98.5025$$

$F(0.9, 2, 4) = 4.32 \rightarrow F_{\text{comp}} > F(0.9, 2, 4) \rightarrow \text{SIM a regressão é significativa}$

# Exercício 4

b ) Quais variáveis previsoras são significativas com 90% de confiança?

IC de 90% para  $b_1$  e  $b_2$   $\rightarrow t_{0.95,4} = 2.132$

desvios padrões

$$s_{b1} = s_e \sqrt{c_{11}} = 1.2 \sqrt{0.0280} = 0.2008$$

$$s_{b2} = s_e \sqrt{c_{22}} = 1.2 \sqrt{0.0012} = 0.04157$$

IC:

$$b_1: 0.1182 \pm 2.132 * 0.2008 = 0.1182 \pm 0.4281 \rightarrow \text{Não é significativo}$$

$$b_2: 0.0165 \pm 2.132 * 0.04157 = 0.0165 \pm 0.0886 \rightarrow \text{Não é significativo}$$

## Exercício 4

c) Qual variável previsora você consegue estimar com maior precisão, para uma confiança de 90%? Justifique apresentando a precisão que você pode atribuir a cada variável com a dada confiança.

Erro máximo associado à estimativa de  $b_1$ :  $0.4281/0.1182 = 3.6218$

Erro máximo associado à estimativa de  $b_2$ :  $0.0886/0.0165 = 5.3712$

Logo, aparentemente, a maior precisão é da variável  $b_1$ . Entretanto, esta precisão está muito baixa (erro máximo por um fator de quase 4). Além disto, há problemas de inconsistências na regressão o que levanta questionamentos sobre validade do modelo.

# Exercício 4

d) Você está satisfeito com seu modelo? Justifique. Se não, qual seria seu próximo passo?

Não; há sinais de multicolineariedade. Seria interessante avaliar as regressões simples com cada previsor separadamente e ver qual leva ao melhor resultado.